COMPLAINT-TRIAGE

Données et scoring

Collecte des données, exploration, modèles et décision

Nathan Mang
Octobre 2026
Rapport de fin de version

Synthèse

Cette version construit le socle de données et répond à la question posée au cadrage : un modèle classe-t-il les réclamations bancaires mieux qu'une règle simple, assez pour justifier son coût ?

Les données viennent des publications officielles du CFPB : 627 297 réclamations sur les cartes de crédit et les comptes courants et d'épargne, de 2022 à octobre 2026, dont 47,5 % avec le récit du client. Après le retrait des gestionnaires de fichiers de consommateurs et des dossiers trop récents pour que leur issue soit connue, 523 552 réclamations servent à la modélisation. Le pipeline est testé, contrôlé à chaque exécution et relancé par l'intégration continue à chaque modification.

Le critère fixé au cadrage est la Capture@10 % : chaque semaine, chaque banque traite d'abord 10 % de sa file, et l'on mesure la part des réclamations finalement indemnisées qui s'y trouvent. Le modèle doit faire au moins 5 points de mieux que la règle de référence, les taux historiques d'indemnisation de la banque par motif.

Question	Réponse sur la période de test (janvier à juillet 2026)
Le modèle sans texte bat-il la règle ?	Non : XGBoost fait 0,5 point de moins que la règle (17,0 % contre 17,4 %). La règle est retenue.
Que vaut le texte ?	Environ 2,6 points de Capture@10 % et 0,063 de PR-AUC : le critère est atteint, mais le CFPB ne publie plus les récits
L'outil est-il équitable ?	Oui, une fois la file séparée par produit : rapports de 0,93 à 1,12 entre sous-groupes
Ses notes sont-elles fiables ?	Oui : erreur de calibration de 0,024, sous le seuil de 0,05

Table 1 – Les réponses de la v0.1

Deux corrections de méthode ont marqué la version. La mesure classait d'abord toutes les banques ensemble, ce qui récompensait les modèles capables de reconnaître la banque ; elle classe désormais dans la file de chaque établissement. Le contrôle d'équité a ensuite montré qu'avec une seule file par banque, les clients des comptes courants passaient après ceux des cartes de crédit ; chaque produit a désormais sa propre file. Ces deux corrections ont rendu l'évaluation plus exigeante, et toutes deux sont documentées dans ce rapport.

La suite du projet (RAG, agent, mise en production) s'appuie donc sur la règle propre à chaque banque, appliquée à la file de chaque produit.

Table des matières

Synthèse 1

1 Collecte et premier traitement 3

2 Intégration continue 8

3 Exploration des données 9

4 Cadre d’évaluation et règle de référence 14

5 Modèle XGBoost sur les variables structurées 16

6 Correction de la métrique d’évaluation 20

7 Ce qu’apporte le texte 22

8 Équité et calibration 24

9 Décision sur la période de test 28

10 Conclusion de la v0.1 31

1. Collecte et premier traitement

1.1 Objectif

Cette première étape transforme les fichiers publiés par le CFPB en un seul jeu de données propre, vérifié et reproductible. Toutes les étapes suivantes (exploration, modèles, agent) partiront de ce fichier, jamais des sources brutes. Si une erreur apparaît dans les sources, elle doit être repérée ici, avant de fausser un modèle.

1.2 Deux sources qui se complètent

Le CFPB publie deux jeux de fichiers. Aucun ne suffit seul.

Source	Ce que je prends	Pourquoi
Export complet (zip de 340 Mo, mis à jour chaque jour)	Toutes les colonnes structurées, dont l'issue de chaque réclamation	C'est la seule source où l'issue est à jour. Pour un dossier reçu en septembre, l'issue n'est souvent connue qu'en octobre.
Archive des récits (19 fichiers, 2021 à août 2026)	L'identifiant et le texte du récit	Le texte n'est plus publié ailleurs depuis le 14 août 2026. En revanche, l'issue y est figée au jour de la publication, donc souvent encore « en cours ».

Table 2 – Ce que chaque source apporte

Les deux sources sont reliées par l'identifiant de la réclamation (`Complaint ID`). Une réclamation sans récit reste dans le jeu de données, avec un récit vide.

J'ai préféré l'export complet à l'API, que j'avais utilisée pour l'étude de faisabilité. L'API renvoie les résultats par pages et il aurait fallu plus de 600 requêtes pour tout récupérer, avec le risque d'en perdre une en route. L'export est un seul fichier, daté, dont on peut vérifier l'intégrité. L'API servira plus tard, pour la collecte quotidienne des nouvelles réclamations.

1.3 Le chemin des données

Les données passent par trois dossiers, toujours dans le même sens :

- `data/raw/` contient les fichiers téléchargés, que l'on ne modifie jamais ;
- `data/interim/` contient le jeu de données assemblé et vérifié, résultat de cette étape ;
- `data/processed/` contiendra les variables prêtes pour les modèles (étape 4).

Cette séparation a une conséquence pratique : si une règle de traitement change, il suffit de relancer le traitement à partir de `raw/`, sans rien retélécharger et sans jamais travailler sur des fichiers déjà modifiés à la main. Aucun de ces dossiers n'est versionné dans Git.

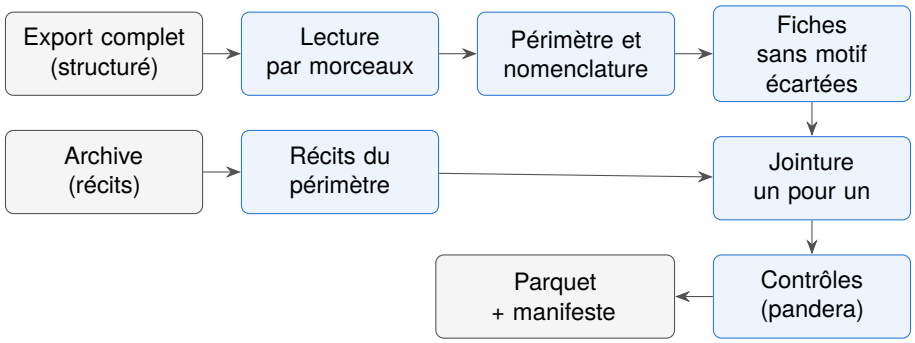


Figure 1 – Les étapes du traitement. En gris, les fichiers ; en bleu, les traitements.

1.4 Les étapes du traitement

Étape	Ce qu'elle fait	Pourquoi
Téléchargement	Récupère les fichiers une seule fois, en passant par un fichier temporaire renommé seulement une fois complet	Une coupure réseau ne doit jamais laisser un fichier tronqué que l'on prendrait pour valide
Lecture par morceaux	Lit l'export 250 000 lignes à la fois et ne garde que le périmètre	L'export complet dépasse 2 Go une fois décompressé : le charger en entier saturerait la mémoire
Nomenclature	Répartit l'ancienne catégorie « Credit card or prepaid card » selon le sous-produit	Avant 2023, cartes de crédit et cartes prépayées étaient mélangées ; seules les premières entrent dans le périmètre
Fiches sans motif	Écarte les réclamations dont le motif est vide, et les compte	Le motif est indispensable pour classer une réclamation
Récits	Lit l'archive en ne gardant que les identifiants du périmètre	L'archive contient des millions de récits, tous produits confondus
Jointure	Associe chaque réclamation à son récit, en refusant toute duplication	Un identifiant présent deux fois créerait des doublons, et des scores faussement bons
Contrôles	Vérifie toutes les règles du jeu de données	Le traitement s'arrête si une seule règle est violée
Écriture	Enregistre le résultat au format Parquet, avec un manifeste	Voir ci-dessous

Table 3 – Ce que fait chaque étape, et pourquoi

Le format Parquet remplace ici le CSV pour trois raisons. Les types sont conservés : une date reste une date, un identifiant reste un entier. On peut lire seulement les colonnes utiles. Enfin, le fichier est compressé. Le jeu de données final occupe 186 Mo, récits compris.

1.5 Les contrôles de qualité

Les règles sont écrites avec la bibliothèque *pandera*. Les principales sont les suivantes :

— chaque identifiant est unique ;

— le produit appartient au périmètre (carte de crédit, compte courant ou d'épargne) ;

— l'issue fait partie des cinq valeurs connues ;

— le motif, l'établissement et le canal de dépôt sont toujours renseignés ;

— aucune colonne inattendue n'apparaît.

Les contrôles signalent toutes les erreurs en une fois, au lieu de s'arrêter à la première. C'est utile sur des centaines de milliers de lignes : on obtient la liste complète des problèmes en un seul passage.

Ces contrôles ont servi dès le premier passage sur les vraies données. Le traitement s'est arrêté sur une erreur : 5 réclamations n'avaient pas de motif. Ce sont toutes des comptes courants transmis par une autre administration (canal *Referral*), reçus entre mars et mai 2024, sans motif ni sous-produit. Toutes les autres règles étaient respectées.

J'avais deux options. Assouplir la règle aurait laissé passer, plus tard, des milliers de lignes vides si la source se dégradait. J'ai préféré écarter explicitement ces 5 fiches : le traitement les compte, l'écrit dans le manifeste et un test vérifie ce comportement. La règle reste stricte, et la décision est visible.

Une règle de qualité ne se désactive pas quand elle bloque. On corrige la donnée ou on documente une exception, de façon visible et testée.

1.6 La traçabilité

À côté du jeu de données, le traitement écrit un manifeste au format JSON. Il indique la date de construction, la date de l'export utilisé, la date de début retenue, le nombre de lignes, le nombre de récits, le nombre de fiches écartées, et pour chacune des 20 sources son adresse, sa taille et son empreinte SHA-256.

L'empreinte permet de savoir, des mois plus tard, sur quelle version exacte des fichiers un modèle a été entraîné. C'est important ici parce que l'export change chaque jour : les issues des dossiers récents évoluent.

1.7 Les tests

Le module est couvert par 25 tests automatiques, qui s'exécutent en quelques secondes. Ils n'utilisent ni le réseau ni les vraies données : chaque test fabrique ses propres petites données, au format exact du CFPB. Ils vérifient notamment :

— qu'un fichier déjà présent n'est pas retéléchargé ;

— qu'une coupure réseau ne laisse aucun fichier partiel ;

— que les anciennes cartes prépayées sont bien exclues et les anciennes cartes de crédit conservées ;

— qu'un récit présent dans deux fichiers d'archive n'est gardé qu'une fois, dans sa dernière version ;

— que le jeu de données final respecte toutes les règles.

Pour tester le téléchargement sans réseau, la fonction qui ouvre une adresse web est passée en paramètre. En production, c'est la vraie connexion ; dans les tests, une fausse fonction renvoie des octets préparés à l'avance, ou simule une coupure.

1.8 Le jeu de données obtenu

Indicateur	Valeur
Réclamations	627 297
dont cartes de crédit	332 520
dont comptes courants ou d'épargne	294 777
Période de réception	1er janvier 2022 – 16 octobre 2026
Réclamations avec récit	297 874 (47,5 %)
Fiches écartées faute de motif	5
Établissements différents	1 290
Taille sur disque	186 Mo

Table 4 – Résultat du traitement (export du 17 octobre 2026)

Issue de la réclamation	Nombre	Part
Clôturée avec explication	453 907	72,4 %
Clôturée avec indemnisation financière	87 043	13,9 %
Clôturée avec correction non financière	78 042	12,4 %
Encore en cours	7 681	1,2 %
Réponse hors délai	624	0,1 %

Table 5 – Répartition de la variable cible

1.9 Ce que nous apprend ce premier traitement

La cible correspond au cadrage

13,9 % des réclamations aboutissent à une indemnisation financière (14,5 % pour les cartes, 13,1 % pour les comptes). Le chiffre de l'étude de faisabilité est confirmé sur les données complètes.

Les dossiers récents n'ont pas encore d'issue

1,2 % des réclamations sont encore en cours, presque toutes reçues dans les trois derniers mois. La règle prévue au cadrage, attendre 90 jours avant d'utiliser une réclamation pour l'entraînement, reste nécessaire. Elle sera vérifiée à l'étape 3.

Le texte est disponible pour environ la moitié des dossiers

La part des réclamations avec récit est de 51 % en 2022, 58 % en 2023, 50 % en 2024 et 53 % en 2025, puis tombe à 29 % en 2026 à cause de l'arrêt de la publication. Un modèle de texte disposera donc d'environ 256 000 récits sur 2022-2025, ce qui est largement suffisant.

Les établissements sont très concentrés

Les cinq premiers (JPMorgan Chase, Capital One, Bank of America, Wells Fargo, Citibank) reçoivent 41 % des réclamations. Un modèle pourrait apprendre surtout les habitudes de ces cinq banques. L'évaluation devra donc être faite aussi établissement par établissement.

Les sous-groupes sont assez grands pour l'analyse d'équité

9 % des réclamations portent l'étiquette *Older American*, 9 % *Servicemember* et 2 % les deux, soit plusieurs dizaines de milliers de dossiers par groupe.

Une partie du périmètre ne concerne pas des banques

C'est la découverte la plus importante de cette étape. Les trois agences d'évaluation du crédit (Equifax, Experian et TransUnion) totalisent 58 328 réclamations dans notre périmètre, soit 9,3 %, presque toutes classées en « carte de crédit ». Il s'agit en réalité de contestations de rapports de crédit, que le cadrage voulait exclure. Leur taux d'indemnisation est de 0,1 %, contre 15,3 % pour les banques.

Établissement	Réclamations	Indemnisation financière
Agences d'évaluation du crédit (3)	58 328	0,1 %
Banques et autres établissements	568 969	15,3 %

Table 6 – Deux populations très différentes dans le même périmètre

Si on les garde, un modèle apprendra très vite qu'une réclamation contre une agence n'aboutit presque jamais à une indemnisation. Ses scores paraîtront bons, mais ce sera un gain facile, sans intérêt pour une banque, qui ne reçoit pas ces réclamations. Je propose de les retirer du périmètre à l'étape 3, après avoir vérifié qu'aucune autre catégorie ne se comporte de la même façon. La décision sera documentée dans l'ADR de la v0.1.

Une petite correction des chiffres du cadrage

Les séries mensuelles du rapport v0.0 comptaient toute l'ancienne catégorie « Credit card or prepaid card », donc aussi 6 066 réclamations sur cartes prépayées en 2022 et 2023, soit environ 1 % du volume de ces deux années. Les conclusions du cadrage ne changent pas. Les chiffres de ce rapport utilisent la nomenclature corrigée.

1.10 Limites et questions pour la suite

- Le jeu de données reflète l'export d'un jour donné. Reconstruit dans un mois, il contiendra des issues différentes pour les dossiers récents. Le manifeste permet de savoir quelle version a été utilisée.
- Le pic de janvier 2025 repéré pendant le cadrage n'est pas encore expliqué.
- Le traitement des agences d'évaluation du crédit reste à trancher.
- La règle des 90 jours doit être confirmée par la courbe de maturité des issues.

Ces points sont le programme de l'étape 3.

1.11 Ce que la relecture du code a changé

Avant la fusion, j'ai relu le code comme une pull request en entreprise. Il fonctionnait sur les vraies données, et pourtant la relecture a trouvé quatre défauts, qui ne se déclenchaient que dans des cas moins courants.

Défaut	Correction
Le manifeste ne donnait pas la date de l'export. Or l'export est réutilisé depuis le cache, et c'est sa date qui fixe les issues connues (règle des 90 jours).	Le manifeste indique la date de l'export, distincte de la date de construction.
L'option de rafraîchissement supprimait l'export en cache avant d'avoir téléchargé le nouveau.	Le nouvel export ne remplace l'ancien qu'une fois complet.
Un fichier tronqué, sans erreur réseau, aurait été accepté.	La taille reçue est comparée à la taille annoncée par le serveur ; une erreur 404 n'est plus réessayée.
Une période sans fichier d'archive faisait planter la lecture des récits.	La lecture renvoie un tableau vide.

Table 7 – Défauts trouvés en relecture

Pour chaque défaut, j'ai d'abord écrit un test qui reproduit le problème, puis vérifié qu'il échouait sur l'ancien code : 6 des 7 nouveaux tests échouaient, le septième vérifiant seulement qu'un cas normal reste accepté. Un test de correction qui passe déjà avant la correction ne prouve rien.

2. Intégration continue

2.1 Objectif

Jusqu'ici, les contrôles (lint, format, typage, tests) ne tournaient que sur mon ordinateur, avant chaque commit. Rien ne garantissait qu'ils passeraient ailleurs : un fichier oublié dans un commit, une dépendance installée seulement sur ma machine ou une différence entre Windows et Linux passeraient inaperçus.

L'intégration continue relance ces contrôles sur un serveur de GitHub, dans un environnement vierge, à chaque pull request et à chaque modification de la branche principale. Une fois la branche principale protégée, GitHub refuse la fusion d'une pull request tant que ces contrôles ne sont pas tous passés.

2.2 Le fonctionnement

Le workflow tient dans un fichier, `.github/workflows/ci.yml`. Il exécute les étapes suivantes sur une machine Ubuntu 24.04 :

Étape	Rôle	Durée
Installation	Python 3.12 et les versions exactes des dépendances du `uv.lock`. L'option `--locked` fait échouer la CI si ce fichier n'est plus à jour.	1 s
Lint	ruff signale les erreurs courantes et les règles de sécurité.	< 1 s
Format	ruff vérifie que le code est formaté, sans le modifier.	< 1 s
Typage	mypy en mode strict.	7 s
Tests	Les 25 tests unitaires, sans réseau.	2 s

Table 8 – Étapes de la CI (exécution du 17 octobre 2026, 22 s au total)

Trois réglages limitent les risques. La CI n'a que des droits de lecture sur le dépôt : un workflow qui peut écrire est une faille classique. Un nouveau push sur une branche annule l'exécution

précédente, devenue inutile. Enfin, la version de uv est fixée à celle utilisée en local.

2.3 Deux enseignements de la mise en place

La première exécution a échoué au bout de 3 secondes. L'action qui installe uv était appelée avec la référence `v10`, que son auteur ne publie pas : il ne diffuse que des versions précises, comme `v10.3.0`. Le fichier de CI n'avait jamais tourné. Comme le code, il se teste en l'exécutant.

La même exécution affichait un avertissement : la machine `ubuntu-latest` allait passer à Ubuntu 26 deux jours plus tard. J'en ai tiré deux règles :

— chaque action est référencée par l'empreinte exacte de son commit, avec la version en commentaire. Une étiquette comme `v7` peut être déplacée par l'auteur de l'action, ou par quelqu'un qui aurait pris le contrôle de son dépôt ; une empreinte ne bouge pas ;

— le système est fixé à Ubuntu 24.04. Un environnement qui change tout seul rend les pannes impossibles à reproduire.

C'est le même principe que le fichier `uv.lock` pour les bibliothèques Python : savoir exactement ce qui s'exécute, et décider soi-même quand cela change.

3. Exploration des données

3.1 Objectif

Avant de modéliser, il fallait répondre à cinq questions laissées ouvertes par le cadrage et par la collecte. À partir de quand l'issue d'une réclamation est-elle connue ? Que faire des réclamations qui ne visent pas des banques ? D'où vient le pic de janvier 2025 ? Quelles colonnes peut-on utiliser sans tricher ? Quels motifs mènent le plus souvent à une indemnisation ?

Toutes les analyses de cette section sont recalculées par le script `scripts/analysis/explore_dataset.py`, qui produit les tableaux et les figures à partir du jeu de données collecté. Les décisions qui en découlent sont appliquées par le module `complaint_triage.data.prepare` et couvertes par des tests.

3.2 Quand l'issue d'une réclamation est-elle connue ?

Pour chaque réclamation, j'ai calculé son âge à la date de l'export, puis la part de dossiers encore en cours et la part de dossiers indemnisés, par tranche d'âge.

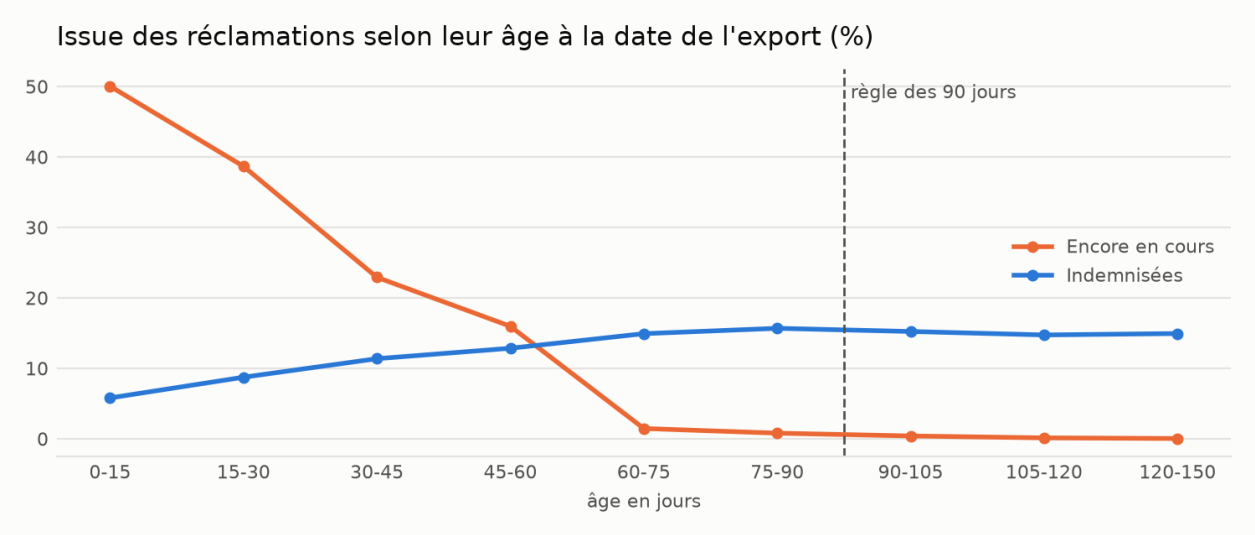


Figure 2 – Issue des réclamations selon leur âge à la date de l'export du 17 octobre 2026.

La moitié des dossiers de moins de 15 jours sont encore en cours. Cette part tombe à 16 % entre 45 et 60 jours, puis brusquement à 1,5 % entre 60 et 75 jours, et à 0,4 % entre 90 et 105 jours. Au-delà de 90 jours, il ne reste que 51 dossiers en cours sur plus de 580 000.

Le taux d'indemnisation, lui, monte de 5,8 % à environ 15 % pendant que les dossiers mûrissent. C'est exactement le biais attendu : un modèle entraîné sur des dossiers récents verrait un taux d'indemnisation deux fois trop faible.

La règle des 90 jours prévue au cadrage est donc confirmée. Un seuil de 60 jours serait possible, mais les issues bougent encore un peu entre 60 et 90 jours (1,5 % puis 0,8 % de dossiers en cours). Je garde 90 jours par prudence. Le coût est connu : les 41 373 réclamations des trois derniers mois ne servent pas à l'entraînement. Les 51 dossiers anciens encore en cours sont retirés eux aussi.

3.3 Des établissements qui ne sont pas des banques

La collecte avait révélé que les trois agences d'évaluation du crédit représentaient 9,3 % du périmètre. En cherchant tous les établissements de plus de 1 000 réclamations dont le taux d'indemnisation est inférieur à 1 %, j'en ai trouvé douze.

Établissement	Réclamations	Indemnisées	Nature
Equifax	20 452	0,00 %	gestionnaire de fichiers
TransUnion	19 509	0,01 %	gestionnaire de fichiers
Experian	18 367	0,17 %	gestionnaire de fichiers
Block (Cash App)	10 303	0,29 %	fournisseur du produit
Robinhood	2 253	0,00 %	fournisseur du produit
Early Warning Services	2 093	0,00 %	gestionnaire de fichiers
FIS (ChexSystems)	1 845	0,05 %	gestionnaire de fichiers
Netspend, Avant, Self Financial, Affirm, Continental Finance	6 417	0 à 1 %	fournisseurs du produit

Table 9 – Établissements de plus de 1 000 réclamations avec moins de 1 % d'indemnisation

Ce tableau mélange deux situations. Les gestionnaires de fichiers tiennent des registres sur les

consommateurs : rapports de crédit pour Equifax, Experian et TransUnion, fichiers d'incidents bancaires pour Early Warning Services et FIS. Les réclamations qu'ils reçoivent contestent un rapport ou un refus d'ouverture de compte (1 299 des 2 093 réclamations visant Early Warning Services portent sur l'ouverture d'un compte). Ils ne tiennent ni le compte ni la carte du client, et une banque ne reçoit jamais ces réclamations.

Les autres, comme Block ou Affirm, vendent eux-mêmes le produit. Leur taux nul reflète une pratique de l'établissement, que le modèle doit pouvoir apprendre.

J'exclus donc les six gestionnaires de fichiers, LexisNexis compris (55 réclamations), soit 62 321 réclamations. Les fournisseurs du produit restent. L'exclusion n'est pas faite pendant la collecte mais pendant la préparation : le jeu collecté reste complet, et cette analyse peut être recalculée à tout moment.

3.4 Le pic de janvier 2025

Janvier 2025 compte 27 440 réclamations, contre 11 580 en moyenne pour les deux mois voisins. Le détail par jour montre deux vagues distinctes.

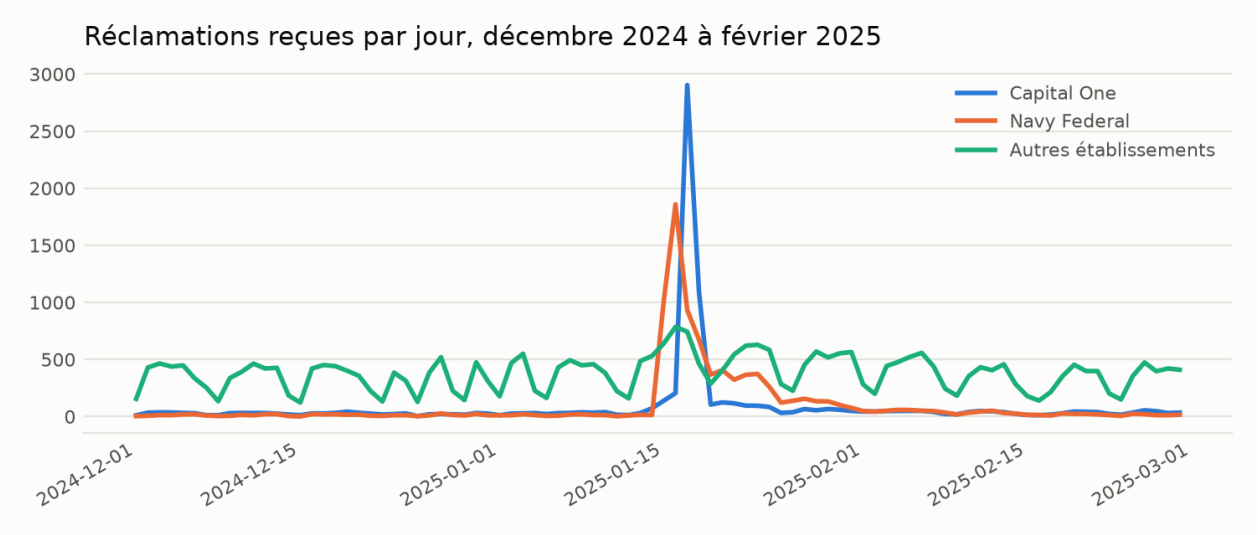


Figure 3 – Réclamations reçues par jour autour du pic de janvier 2025.

La première vise Navy Federal, du 15 au 18 janvier : 7 615 réclamations dans le mois contre 615 habituellement, presque toutes sur des frais de découvert. 46 % des récits sont identiques mot pour mot et renvoient aux « récentes conclusions du CFPB ». En novembre 2024, le CFPB avait en effet ordonné à Navy Federal de rembourser plus de 80 millions de dollars de frais de découvert jugés abusifs [1]. Tout indique un modèle de lettre qui a circulé.

La seconde vise Capital One, surtout les 17 et 18 janvier : des dépôts de salaire non crédités. Elle correspond à une panne chez son prestataire FIS, qui a bloqué dépôts et paiements du 15 au 19 janvier 2025 [2].

Dans les deux cas, le taux d'indemnisation est d'environ 2 %, contre 13 % d'habitude. Ce ne sont pas des erreurs de données mais de vrais événements. Je les garde : un outil de priorisation doit justement savoir traiter ce type de vague. Ils resteront dans la période d'entraînement, puisque le test portera sur les mois les plus récents.

1. https://www.consumeraffairs.com/news/navy-federal-credit-union-ordered-to-refund-more-than-80-million-110724.html
2. https://www.wbrc.com/2025/01/17/users-report-issues-with-deposits-payments-during-capitol-one-outage

3.5 Les récits répétés

Le pic de janvier a fait apparaître un phénomène plus général : des récits identiques, mot pour mot, déposés par plusieurs personnes.

Année	Récits	Part répétée	Indemnisés (répétés)	Indemnisés (uniques)
2022	37 643	0,4 %	3,1 %	18,3 %
2023	60 561	11,2 %	0,1 %	17,3 %
2024	64 936	6,8 %	0,2 %	17,4 %
2025	92 964	7,7 %	0,2 %	13,8 %
2026	41 770	0,8 %	3,6 %	15,5 %
Toute la période	297 874	6,3 %	0,25 %	16,1 %

Table 10 – Récits présents en plusieurs exemplaires identiques

Un récit recopié n'aboutit presque jamais à une indemnisation (0,25 % contre 16,1 %). Cela pose deux problèmes pour le modèle de texte de l'étape 6. Le modèle apprendrait facilement « texte recopié = pas d'indemnisation », ce qui gonflerait ses scores sans rien dire de sa capacité à lire une réclamation. Et si deux copies d'un même texte se retrouvaient l'une à l'entraînement et l'autre au test, le modèle serait évalué sur un texte déjà vu. Il faudra donc évaluer ce modèle en tenant compte des copies.

Un autre biais concerne le texte : un récit n'est publié que si le consommateur l'accepte. Pour les cartes, les réclamations avec récit sont plus souvent indemnisées (16,9 %) que celles sans récit (12,3 %). Comparer un modèle avec texte et un modèle sans texte n'aura de sens que sur les mêmes dossiers.

3.6 Les colonnes connues à la réception

Chaque colonne du jeu de données a désormais un rôle explicite.

Rôle	Colonnes
Connues à la réception	date de réception (pour le découpage dans le temps), produit, sous-produit, motif, sous-motif, établissement, État, code postal, étiquettes, canal de dépôt, récit
Connues après coup	date de transmission à l'établissement, réponse publique de l'établissement, respect du délai
Cible	issue de la réclamation

Table 11 – Rôle des colonnes

Les colonnes connues après coup ne servent jamais à prédire. Leur lien avec la cible est mesurable : quand l'établissement publie une réponse, le taux d'indemnisation est de 16,7 %, contre 11,3 % sinon. Un modèle qui utiliserait cette colonne paraîtrait meilleur en test et serait inutilisable à l'arrivée d'une réclamation.

Un test automatique vérifie que chaque colonne du jeu de données a exactement un rôle. Si une colonne est ajoutée un jour, le test échoue tant qu'on n'a pas décidé si elle est connue à la réception. Une fuite d'information ne peut donc pas entrer par oubli.

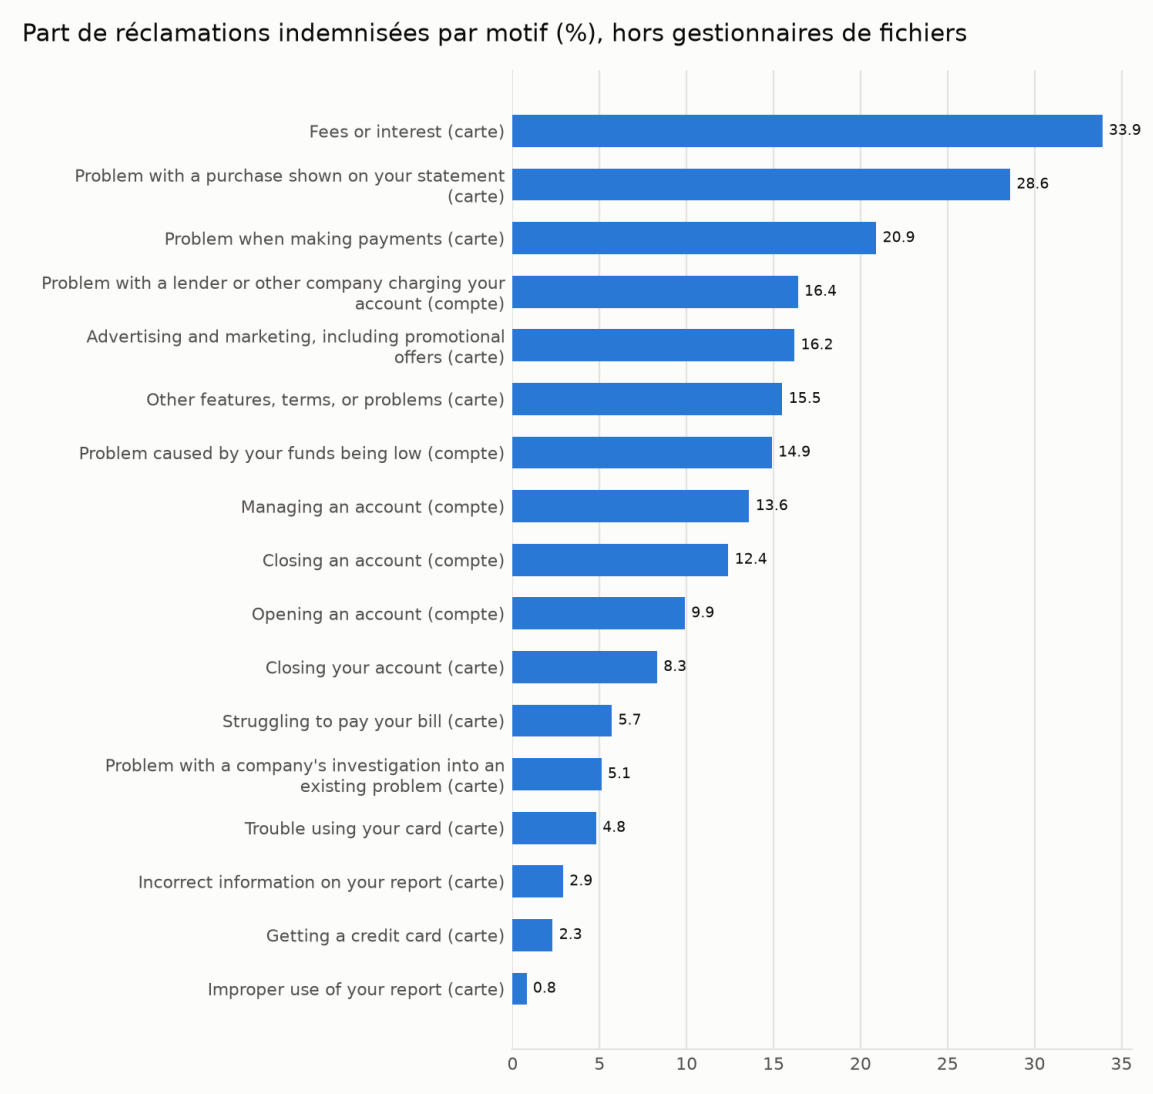


Figure 4 – Part de réclamations indemnisées par motif, pour les motifs d'au moins 2 000 réclamations, sur le jeu préparé.

3.7 Les motifs, base de la règle de référence

Les écarts sont très importants : un tiers des réclamations sur des frais ou intérêts de carte sont indemnisées, contre 2,3 % des demandes d'obtention de carte. La règle H0 du cadrage, qui classe les réclamations selon le taux historique de leur produit, motif et sous-motif, sera donc une référence solide. Le modèle devra apporter davantage que cette seule information.

3.8 Le jeu de données pour la modélisation

Étape	Réclamations
Jeu collecté	627 297
Gestionnaires de fichiers retirés	−62 321
Réclamations de moins de 90 jours retirées	−41 373
Réclamations encore en cours après 90 jours retirées	−51
Jeu préparé pour la modélisation	523 552

Table 12 – Du jeu collecté au jeu préparé

Le jeu préparé ne contient que l'identifiant, les colonnes connues à la réception et la cible, une valeur vrai ou faux qui indique si la réclamation a abouti à une indemnisation financière.

3.9 Décisions prises

Décision	Raison
Garder la règle des 90 jours	Moins de 0,4 % de dossiers en cours après 90 jours, alors que le taux d'indemnisation monte encore avant
Retirer six gestionnaires de fichiers (62 321 réclamations)	Ils ne tiennent pas les comptes ; une banque ne reçoit pas ces réclamations
Garder les fournisseurs du produit à taux nul	Leur comportement fait partie du problème réel
Garder le pic de janvier 2025	Deux événements réels, documentés par des sources publiques
Tenir compte des récits recopiés pour le modèle de texte	6,3 % de copies, indemnisées à 0,25 %
Comparer les modèles sur les mêmes dossiers	Le récit n'est publié qu'avec l'accord du consommateur
Liste fermée des colonnes, vérifiée par un test	Une réponse publique de la banque est liée à l'issue

Table 13 – Décisions de l'étape d'exploration

4. Cadre d'évaluation et règle de référence

Les résultats de cette section classent toutes les banques ensemble. La section 6 montre pourquoi cette mesure a été corrigée, et donne les résultats dans la file de chaque établissement. Ceux de cette section sont conservés comme trace de ce qui avait été mesuré.

4.1 Objectif

Cette étape construit le cadre qui servira à juger tous les modèles, puis mesure la règle de référence H0 définie au cadrage. Le résultat est la barre que le modèle devra dépasser.

4.2 Le découpage dans le temps

Le jeu préparé est coupé en trois périodes qui se suivent.

Période	Dates de réception	Réclamations	Semaines	Indemnisées
Entraînement	janvier 2022 – juin 2025	349 695	184	16,0 %
Validation	juillet – décembre 2025	74 768	27	14,5 %
Test	janvier – juillet 2026	99 089	29	15,2 %

Table 14 – Les trois périodes du jeu préparé

Un découpage au hasard aurait mélangé des réclamations de 2026 dans l'entraînement. Le modèle aurait appris des tendances futures et ses scores auraient été trop optimistes. En production, il prédit toujours le futur à partir du passé : l'évaluation doit faire de même. Le taux d'indemnisation varie d'ailleurs d'une période à l'autre (16,0 %, 14,5 %, 15,2 %), ce qui confirme que les données dérivent.

La validation sert à comparer et à régler les modèles. Le test n'est regardé qu'une seule fois, pour la décision finale de la v0.1. Si on l'utilisait pour ajuster les modèles, il deviendrait une seconde validation et ne mesurerait plus rien d'honnête. C'est pourquoi aucun résultat de test n'apparaît dans cette section.

4.3 La Capture@10 % en pratique

La métrique suit le fonctionnement d'un service réclamations. Chaque semaine, les réclamations reçues sont classées ; l'équipe traite d'abord les 10 % du haut. La Capture@10 % est la part des réclamations finalement indemnisées qui se trouvent dans ces 10 %. Les semaines sont ensuite cumulées : on additionne les dossiers indemnisés captés et les dossiers indemnisés au total.

Un détail compte. La règle H0 donne la même note à toutes les réclamations d'une même catégorie, si bien que beaucoup de dossiers sont ex æquo. Quand un groupe d'ex æquo est coupé par la limite des 10 %, je ne départage pas au hasard : je compte la part de ses positifs proportionnelle aux places restantes, ce qui donne la valeur moyenne exacte. Un test vérifie qu'un classement où toutes les notes sont égales capte exactement 10 %, comme le hasard.

L'incertitude est mesurée par bootstrap : on tire au hasard, avec remise, des semaines entières, et on recalcule la Capture à chaque tirage, 2 000 fois. On tire des semaines et non des réclamations, parce que les réclamations d'une même semaine se ressemblent (le pic de janvier 2025 l'a montré). Pour comparer deux classements, les deux sont recalculés sur les mêmes semaines tirées : c'est l'écart lui-même qui reçoit un intervalle de confiance.

4.4 La règle H0

H0 note chaque réclamation par le taux d'indemnisation de sa catégorie (produit, motif et sous-motif) observé sur l'entraînement. Une catégorie rare est rapprochée de sa catégorie parente :

$$\text{taux} = \frac{\text{indemnisées} + m \times \text{taux parent}}{\text{réclamations} + m}, \qquad m = 20.$$

Sans ce lissage, une catégorie vue deux fois avec une indemnisation aurait un taux de 50 %. Une catégorie jamais vue reçoit le taux de sa catégorie parente.

4.5 Résultats sur la validation

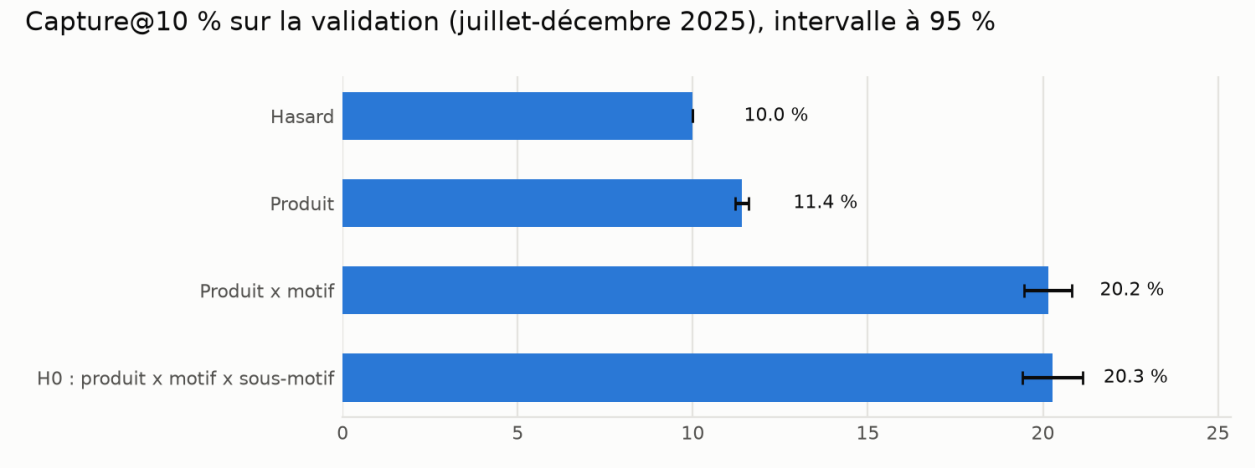


Figure 5 – Capture@10 % des classements de référence sur la période de validation.

Classement	Capture@10 %	Intervalle à 95 %	PR-AUC
Hasard	10,0 %	–	0,14
Produit	11,4 %	11,2 – 11,6	0,16
Produit et motif	20,2 %	19,5 – 20,8	0,23
H0 : produit, motif et sous-motif	20,3 %	19,4 – 21,1	0,25

Table 15 – Classements de référence sur la validation (juillet à décembre 2025)

H0 capte 20,3 % des réclamations indemnisées en traitant 10 % de la file, soit deux fois plus que le hasard. C'est la barre fixée au cadrage : le modèle devra faire au moins 5 points de mieux, soit environ 25 % de Capture@10 %, avec un intervalle de confiance qui reste au-dessus de H0.

Le produit seul apporte peu (11,4 %). Presque tout le gain vient du motif. Le sous-motif ajoute 0,1 point de Capture, avec un intervalle de $-0{,}5$ à $+0{,}7$ point : l'écart est indiscernable de zéro. Il améliore un peu la PR-AUC (0,23 à 0,25), donc le classement sur l'ensemble de la file, mais pas sur les 10 % du haut.

J'ai aussi fait varier le poids du lissage de 0 à 500. La Capture reste entre 20,3 % et 20,5 %. Avec 350 000 réclamations d'entraînement, presque toutes les catégories sont assez grandes pour que leur taux soit fiable. Le lissage ne crée donc pas de gain ici ; il reste un garde-fou pour les catégories rares ou nouvelles, qui apparaîtront en production.

5. Modèle XGBoost sur les variables structurées

Les conclusions de cette section ont été révisées. Mesuré dans la file de chaque établissement (section 6), le gain de 3 points de la variante B disparaît, et aucun modèle sans texte ne fait mieux que les taux propres à chaque banque.

5.1 Objectif

Cette étape entraîne le premier modèle de machine learning du projet, un XGBoost, sur les seules variables connues à l'arrivée d'une réclamation, sans le texte. Il doit battre la règle H0 d'au moins 5 points de Capture@10 %. Chaque essai est enregistré dans MLflow avec ses variables, ses paramètres, ses résultats, la version du code et l'empreinte des données utilisées.

5.2 Les variables

Variable	Décision	Raison
Produit, sous-produit, motif, sous-motif, canal de dépôt, État	utilisées	Connues à la réception
Étiquettes *Older American*, *Servicemember*	exclues	Ce sont les groupes dont on vérifie qu'ils ne sont pas désavantagés : on ne s'en sert pas pour décider
Code postal	exclu	Il peut servir de substitut à l'origine des personnes
Établissement	variante à part	Il serait constant pour une banque cliente
Volumes récents	créés	Nombre de réclamations reçues dans les jours précédents, voir ci-dessous

Table 16 – Variables du modèle

L'exploration a montré que les vagues de réclamations (campagnes, pannes) aboutissent rarement à une indemnisation. J'ai donc créé des compteurs : pour chaque réclamation, le nombre de réclamations reçues dans les 7 jours précédents pour le même établissement et le même motif, et des variantes sur 30 jours, pour l'établissement tous motifs confondus et pour le motif tous établissements confondus. Le jour même est exclu, et les compteurs portent sur toutes les réclamations reçues, y compris celles qui seront écartées ensuite parce que trop récentes : c'est exactement ce que verrait une banque à l'arrivée d'une réclamation. Ces variables ne contiennent donc aucune information du futur, et un test le vérifie.

Les variables textuelles sont données à XGBoost comme des catégories, qu'il découpe lui-même sans encodage préalable. Une catégorie jamais vue à l'entraînement est traitée comme une valeur manquante.

5.3 L'arrêt de l'entraînement

XGBoost ajoute des arbres un par un. Pour savoir quand s'arrêter, il faut un jeu de données qu'il ne voit pas pendant l'entraînement. Utiliser la validation pour cela l'aurait usée avant même de comparer les modèles. J'ai donc mis de côté les trois derniers mois de l'entraînement (avril à juin 2025) : le modèle apprend sur janvier 2022 à mars 2025 et s'arrête quand ses prédictions sur avril-juin cessent de s'améliorer pendant 100 arbres.

Un premier essai mesurait cette amélioration avec la PR-AUC. Le modèle sans volumes s'est alors arrêté après 4 arbres seulement : la PR-AUC du jeu d'arrêt fluctuait au point d'atteindre son maximum dès le début. Avec la log-loss, plus régulière et qui mesure aussi la justesse des probabilités, le même modèle va jusqu'à 80 arbres pour un résultat presque identique (21,6 % au lieu de

21,2 %). C'est la log-loss qui a été retenue.

5.4 Résultats sur la validation

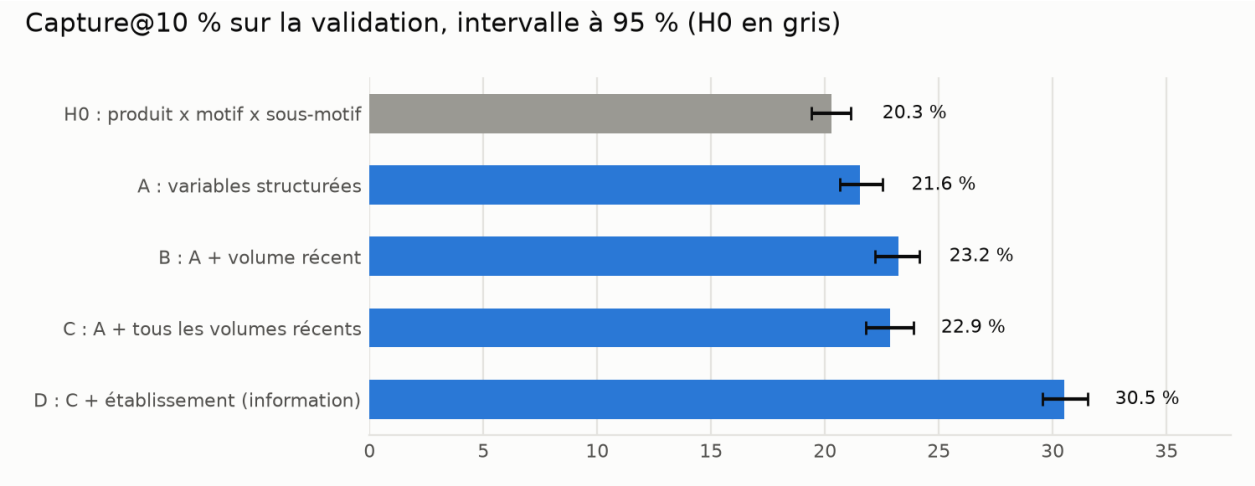


Figure 6 – Capture@10 % des variantes XGBoost et de H0 sur la validation (juillet à décembre 2025).

Modèle	Capture@10 %	Gain sur H0 [IC 95 %]	PR-AUC
H0	20,3 %	–	0,25
A : variables structurées	21,6 %	+1,3 [0,7 ; 1,9]	0,26
B : A + volume récent	23,2 %	+2,9 [2,2 ; 3,7]	0,27
C : A + tous les volumes récents	22,9 %	+2,6 [1,8 ; 3,4]	0,28
D : C + établissement (information)	30,5 %	+10,2 [9,4 ; 11,1]	0,37

Table 17 – Variantes XGBoost sur la validation

Les variables structurées seules apportent 1,3 point. Le compteur de volume récent en apporte 1,6 de plus : c'est un vrai signal. Les compteurs supplémentaires n'ajoutent rien, et la variante C fait même légèrement moins bien que B. Je garde donc B, plus simple.

La variante D montre que l'établissement fait gagner 7 à 8 points de plus. Ce gain vient du fait de savoir quelle banque indemnise le plus souvent. Il ne servirait à rien à une banque qui trie sa propre file, puisque pour elle cette variable est toujours la même. Le cadrage a défini le client comme une banque ; changer cette définition maintenant parce que D passe la barre serait ajuster le critère au résultat. D reste une information, pas un candidat.

5.5 Réglage des paramètres

La validation sert aussi à régler le modèle. Chaque essai supplémentaire augmente cependant le risque de trouver un bon score par chance. J'ai donc fixé un budget de 8 réglages avant de regarder les résultats, sur la variante B.

Réglage	Profondeur	Feuille minimale	Vitesse	Capture@10 %	Gain sur H0
1 (défaut)	6	50	0,05	23,2 %	+2,9
2	4	20	0,05	23,0 %	+2,8
3	4	100	0,05	23,2 %	+2,9
4	6	20	0,05	23,4 %	+3,1
5	6	100	0,05	23,3 %	+3,0
6	8	20	0,05	23,3 %	+3,0
7	8	100	0,05	23,0 %	+2,7
8	6	50	0,02	23,3 %	+3,1

Table 18 – Les 8 réglages de la variante B sur la validation

Les 8 réglages donnent tous entre 23,0 % et 23,4 %. Cet écart de 0,4 point est bien plus petit que l'incertitude de chaque mesure, d'environ un point. Le meilleur, le réglage 4 (+3,1 points, intervalle de 2,5 à 3,8), est retenu comme candidat, en sachant que son avance sur le réglage par défaut n'est pas significative et que son score est légèrement optimiste, puisqu'il a été choisi parmi 8.

La conclusion est surtout la suivante : le modèle ne manque pas de réglages, il manque d'information. Avec les variables connues à l'arrivée et sans l'établissement, il plafonne à environ 3 points au-dessus de H0.

5.6 Ce que le modèle utilise

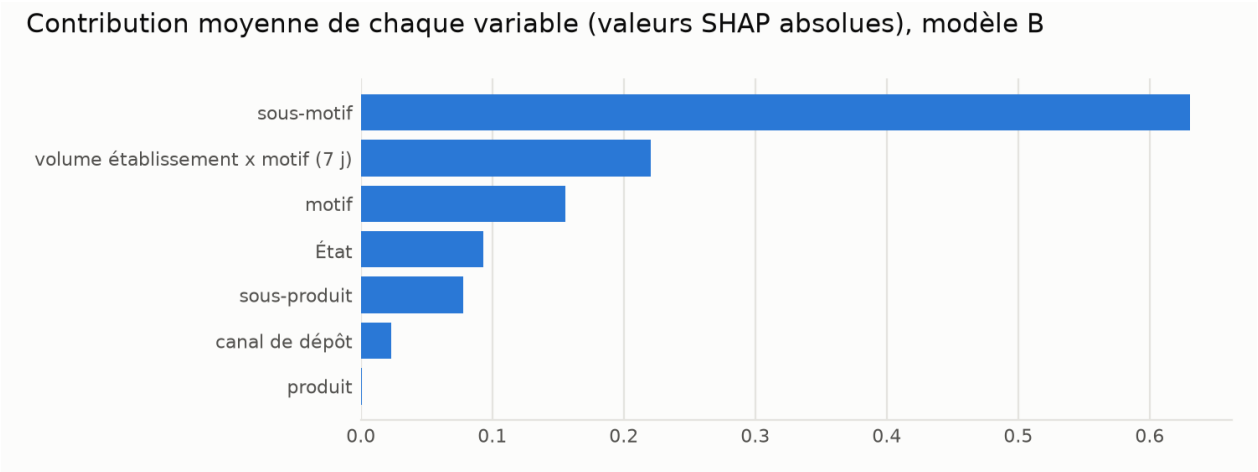


Figure 7 – Contribution moyenne de chaque variable au score du modèle B, mesurée par les valeurs SHAP sur 50 000 réclamations de la validation.

Les valeurs SHAP mesurent, pour chaque réclamation, de combien chaque variable déplace le score. Le sous-motif arrive en tête alors qu'il n'apportait presque rien à H0 par rapport au motif seul. Ce n'est pas contradictoire : chaque sous-motif appartient à un seul motif, si bien qu'il porte aussi l'information du motif, en plus détaillé. Le volume récent arrive en deuxième position, ce qui confirme l'intérêt de cette variable. L'État contribue un peu : c'est une information géographique, dont l'effet sur l'équité sera vérifié à l'étape 7.

5.7 Où en est-on

Constat	Conséquence
Le meilleur modèle éligible bat H0 de 3,1 points sur la validation, intervalle de 2,5 à 3,8	Le gain est réel, mais en dessous des 5 points exigés par le cadrage
Les réglages ne changent presque rien	La marge de progression est dans l'information, pas dans le modèle
L'établissement ferait gagner 7 points de plus	Hors du cadre d'une banque unique ; mesuré pour information

Table 19 – Bilan de l'étape 5

L'étape suivante mesure ce qu'apporte le texte des réclamations. La décision finale sera prise sur la période de test, comme prévu au cadrage : si aucun modèle éligible n'atteint H0 + 5 points, c'est la règle H0 qui sera utilisée pour la suite du projet.

6. Correction de la métrique d'évaluation

6.1 Le défaut

La référence textuelle de l'étape 6 (section suivante) a donné un résultat spectaculaire : 30,2 % de Capture@10 % sur les récits de validation, contre 19,8 % pour H0. En regardant les mots qui pesaient le plus dans ce modèle, j'ai trouvé surtout des noms de banques : *comenity*, *boa*, *citi* ou *bank of america* poussaient vers l'indemnisation, *cash app*, *chime*, *robinhood* ou *affirm* vers l'absence d'indemnisation. Le modèle avait d'abord appris à reconnaître la banque citée dans le récit.

Ce constat révélait un défaut de la métrique elle-même. La Capture@10 % classait toutes les réclamations de la semaine ensemble, toutes banques confondues. Un modèle capable de deviner la banque marquait donc des points : il plaçait en tête les réclamations des établissements qui indemnisent souvent. Or le cadrage définit le client comme une banque qui trie sa propre file. Dans cette file, toutes les réclamations concernent la même banque, et savoir laquelle elle est ne rapporte rien.

6.2 La correction

	Avant	Après
Classement	Toutes les réclamations de la semaine ensemble	Dans la file de chaque établissement, chaque semaine, puis cumul
Référence	Taux du marché par produit, motif et sous-motif	Taux propres à la banque, rapprochés de ceux du marché quand elle a peu de réclamations dans une catégorie
Barre	H0 + 5 points	Inchangée

Table 20 – La métrique avant et après correction

Concrètement, chaque banque traite d'abord 10 % de sa propre file ; on additionne ensuite, semaine par semaine, les réclamations indemnisées captées par toutes les banques. Le bootstrap continue de tirer des semaines entières. La nouvelle référence correspond à ce que ferait un responsable à partir de l'historique de son établissement : ses propres taux d'indemnisation par motif.

Cette correction ne revient pas à changer les règles en cours de route. Elle rapproche la mesure de la définition du client écrite au cadrage, s'applique à tous les modèles de la même façon, et rend l'évaluation plus exigeante en supprimant des gains faciles. La barre de 5 points n'a pas bougé, et aucun modèle ni aucun réglage n'a été ajouté pour la réévaluation : ce sont les mêmes variantes et les mêmes 8 réglages qu'à l'étape 5.

6.3 La réévaluation

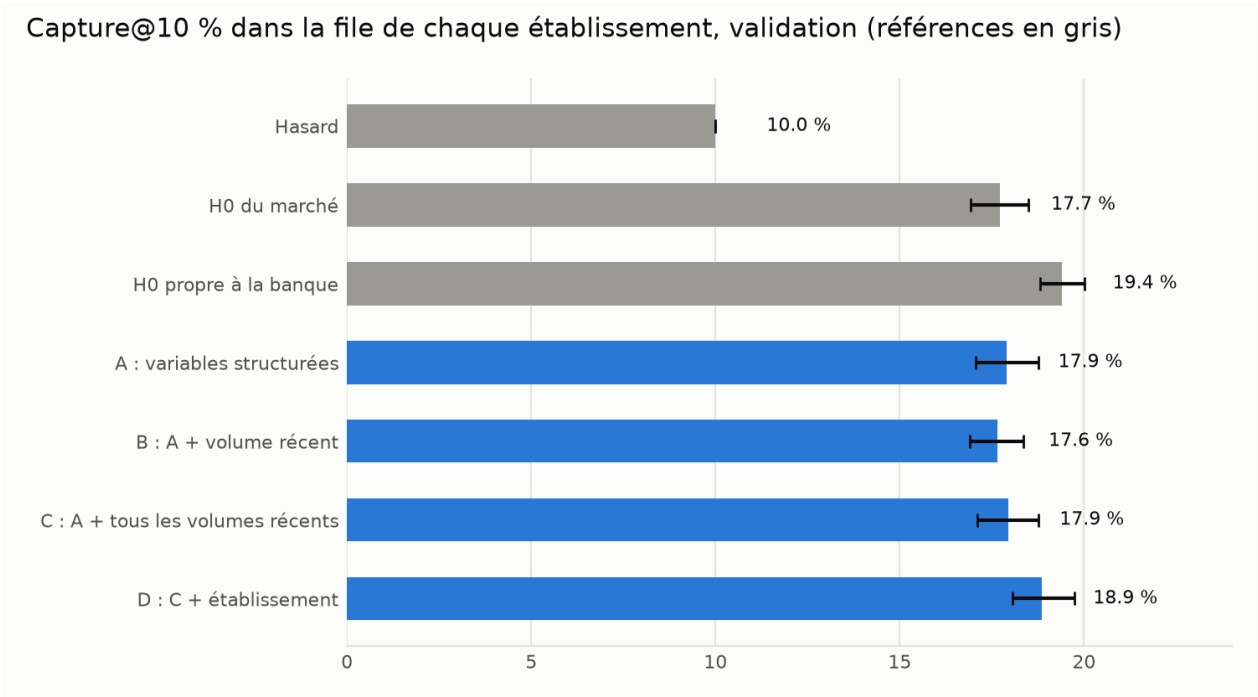


Figure 8 – Capture@10 % dans la file de chaque établissement, sur la validation.

Classement	Banques mélangées	File de chaque banque	Écart avec H0 propre à la banque [IC 95 %]
Hasard	10,0 %	10,0 %	$-9{,}4$
H0 du marché	20,3 %	17,7 %	$-1{,}7$ $[-2{,}2\,;\,-1{,}1]$
H0 propre à la banque	30,2 %	19,4 %	–
A : variables structurées	21,6 %	17,9 %	$-1{,}5$ $[-2{,}1\,;\,-0{,}8]$
B : A + volume récent	23,2 %	17,7 %	$-1{,}7$ $[-2{,}3\,;\,-1{,}1]$
C : A + tous les volumes récents	22,9 %	18,0 %	$-1{,}5$ $[-2{,}2\,;\,-0{,}8]$
D : C + établissement	30,5 %	18,9 %	$-0{,}5$ $[-1{,}2\,;\,+0{,}2]$
D, meilleur des 8 réglages	–	19,4 %	$0{,}0$ $[-0{,}5\,;\,+0{,}5]$

Table 21 – Réévaluation des références et des modèles de l'étape 5

6.4 Ce que la correction change

Sans le texte, aucun modèle ne fait mieux qu'une banque qui calcule ses propres taux historiques par motif. Le meilleur XGBoost l'égale exactement, sans la dépasser.

Le gain de 3 points mesuré à l'étape 5 pour la variante B venait des compteurs de volume par établissement. La variante n'utilisait pas l'établissement, mais ces compteurs le trahissaient : les grandes néobanques reçoivent beaucoup de réclamations et indemnisent peu. Une fois les banques classées séparément, ce gain disparaît.

L'établissement devient au contraire une variable légitime. Dans sa propre file, une banque ne gagne rien à savoir qui elle est ; en revanche, le modèle peut apprendre les habitudes propres à chaque établissement, comme le ferait un modèle entraîné sur l'historique d'une seule banque. C'est pourquoi la variante D, avec son meilleur réglage (profondeur 4, feuille minimale 100), est désormais le modèle sans texte retenu.

La leçon dépasse ce projet. Un modèle peut obtenir un excellent score en exploitant une information qui ne lui servirait à rien en conditions réelles, et seule une métrique fidèle à la situation du client permet de s'en apercevoir. C'est en lisant ce que le modèle utilisait que le défaut est apparu.

7. Ce qu'apporte le texte

7.1 Objectif

Le CFPB ne publie plus le texte des réclamations depuis le 14 août 2026 : le modèle de production devra s'en passer. Mesurer ce que le texte apporte reste utile, pour savoir ce que l'on perd, et pour une banque qui disposerait du texte de ses propres réclamations. La question posée est donc : le texte d'une réclamation apporte-t-il assez d'information pour justifier un modèle ?

7.2 Les données et les précautions

Les récits existent pour 197 291 réclamations d'entraînement, 40 990 de validation et 40 432 de test. Trois précautions issues de l'exploration s'appliquent :

— tous les modèles sont comparés sur les mêmes réclamations, celles qui ont un récit, parce que le récit n'est publié qu'avec l'accord du consommateur et que ces réclamations sont plus souvent indemnisées ;

— la mesure principale exclut les récits de validation déjà présents mot pour mot dans l'entraînement ; ils ne sont que 59 (0,1 %), les campagnes de lettres types étant concentrées dans le temps ;

— dans l'entraînement, chaque récit recopié n'est gardé qu'une fois (4 432 copies retirées), pour qu'une lettre type ne pèse pas autant que des centaines de réclamations différentes.

Les masques du CFPB (`XXXX`) sont retirés et les montants remplacés par un mot commun.

7.3 Les deux modèles de texte

La référence textuelle est une régression logistique sur une représentation TF-IDF : la fréquence de chaque mot et de chaque paire de mots, pondérée pour donner moins de poids aux mots présents partout. Elle s'entraîne en quelques minutes sur un ordinateur portable.

Le modèle de langage est DistilRoBERTa, une version allégée de RoBERTa, fine-tunée pour prédire l'indemnisation à partir du récit. Il lit les 256 premiers tokens, soit environ 200 mots : le récit médian (165 mots) est lu en entier, 29 % des récits sont tronqués. L'entraînement dure au plus deux passages sur les données et s'arrête si la perte sur le jeu d'arrêt ne s'améliore plus pendant trois évaluations successives. Il a tourné sur un GPU de Google Colab, en une quarantaine de minutes. Le code d'entraînement est dans le paquet ; le notebook Colab ne fait que le lancer, et le fichier envoyé sur Colab ne contient pas la période de test.

Deux combinaisons ont aussi été évaluées : la moyenne des rangs du XGBoost retenu et de chaque modèle de texte, à poids égaux. Les poids ont été fixés à l'avance plutôt que réglés sur la validation.

7.4 Résultats

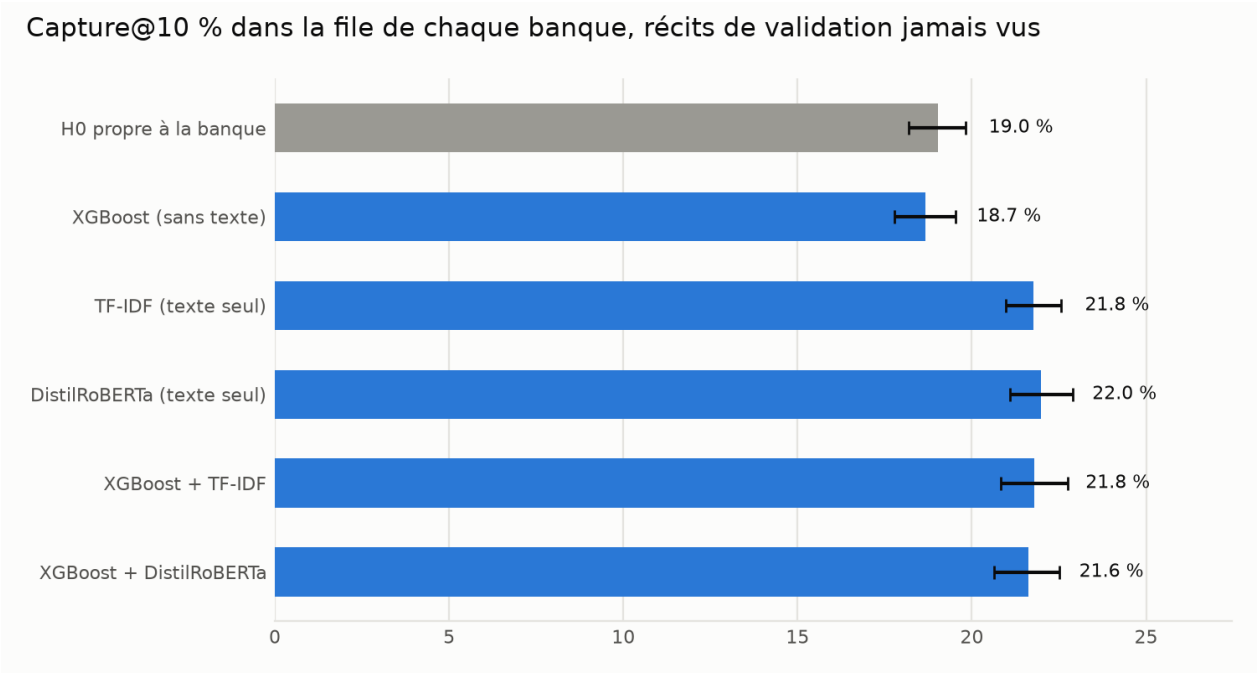


Figure 9 – Capture@10 % dans la file de chaque banque, sur les 40 931 récits de validation jamais vus à l'entraînement.

Modèle	Capture@10 %	Écart avec H0 propre à la banque [IC 95 %]	PR-AUC
H0 propre à la banque	19,0 %	–	0,37
XGBoost (sans texte)	18,7 %	$-0{,}4$ $[-1{,}0\,;\,+0{,}3]$	0,37
TF-IDF (texte seul)	21,8 %	$+2{,}8$ $[1{,}8\,;\,3{,}6]$	0,39
DistilRoBERTa (texte seul)	22,0 %	$+3{,}0$ $[2{,}0\,;\,4{,}0]$	0,41
XGBoost + TF-IDF	21,8 %	$+2{,}8$ $[2{,}0\,;\,3{,}6]$	0,41
XGBoost + DistilRoBERTa	21,6 %	$+2{,}6$ $[1{,}8\,;\,3{,}4]$	0,42

Table 22 – Modèles de texte sur la validation, dans la file de chaque banque

7.5 Analyse

Le texte apporte un gain réel : environ 3 points de Capture@10 % au-dessus des taux propres à chaque banque, avec un intervalle qui ne touche jamais zéro. Ce gain subsiste alors que la mesure neutralise l'effet du nom de la banque : le contenu du récit, et pas seulement l'établissement qu'il cite, renseigne sur l'issue.

Le modèle de langage fait à peine mieux que la référence TF-IDF : 22,0 % contre 21,8 %. L'écart de 0,2 point est bien plus petit que l'incertitude de chaque mesure. Un fine-tuning d'une quarantaine de minutes sur GPU n'apporte donc rien de mesurable par rapport à un modèle linéaire entraîné en quelques minutes sur un processeur. Pour cette tâche, comprendre l'ordre et le sens des phrases ne s'ajoute pas visiblement à la présence des mots. La troncature à 256 tokens peut y contribuer : près d'un récit sur trois n'est lu qu'en partie.

Les combinaisons avec XGBoost n'apportent rien. C'est cohérent avec la section précédente : sans texte, XGBoost ne fait pas mieux que les taux propres à chaque banque, il n'a donc rien à ajouter au texte.

Surtout, aucun modèle n'atteint la barre fixée au cadrage. Même la borne haute de l'intervalle du meilleur modèle (4,0 points) reste en dessous des 5 points exigés.

7.6 Conséquences

Constat	Conséquence
Le texte apporte environ 3 points, de façon certaine	Sa valeur est connue ; elle compte pour une banque qui dispose du texte de ses réclamations
Aucun modèle n'atteint 5 points sur la validation	La règle H0 propre à chaque banque est le candidat le plus probable pour la décision finale
Le modèle de langage égale le TF-IDF	À résultat égal, le modèle le plus simple est préférable
Le texte n'existe plus en production	Le système déployé ne pourra de toute façon s'appuyer que sur les données structurées

Table 23 – Bilan de l'étape 6

La décision sera prise une seule fois, sur la période de test, après l'analyse d'équité de l'étape 7.

8. Équité et calibration

8.1 Objectif

Le cadrage impose deux contrôles avant toute mise en service, et le premier peut à lui seul la bloquer. L'outil ne doit défavoriser aucun groupe de clients, et ses notes doivent pouvoir se lire comme des probabilités. Les deux candidats contrôlés sont ceux qui peuvent fonctionner en production, donc sans le texte : la règle H0 propre à la banque et le XGBoost retenu à la section 6. Tout se mesure sur la validation ; la période de test reste fermée.

8.2 Les mesures

Pour un sous-groupe de clients, je prends ses réclamations finalement indemnisées et je calcule la part que la banque a traitée en priorité, c'est-à-dire dans les 10 % de tête de sa file cette semaine-là. C'est la Capture@10 % restreinte au sous-groupe. Je la compare ensuite à la même mesure pour tous les autres clients. Un rapport de 1 veut dire qu'un client du groupe qui obtient gain de cause a autant de chances qu'un autre d'être traité vite. Le cadrage exige un rapport compris entre 0,8 et 1,25, la règle dite des quatre cinquièmes appliquée dans les deux sens. L'intervalle de confiance tire des semaines entières, comme pour la Capture.

Les sous-groupes sont ceux fixés au cadrage : les clients que le CFPB signale comme âgés (*Older American*, 6 434 réclamations sur la validation) ou militaires (*Servicemember*, 7 094), et le produit. Une réclamation qui porte les deux étiquettes compte dans les deux groupes.

La calibration se mesure par l'erreur de calibration attendue (ECE). On range les réclamations en 10 classes de notes de tailles voisines et on calcule, dans chaque classe, l'écart entre la note moyenne et la part réellement indemnisée ; l'ECE est la moyenne de ces écarts, pondérée par la taille des classes. Le cadrage exige moins de 0,05, soit 5 points de pourcentage. Les notes égales restent dans la même classe : un test a montré qu'autrement, avec les nombreux ex æquo de H0, le résultat dépendait de l'ordre des lignes du fichier.

8.3 Premier résultat : le produit échoue

Sous-groupe	Taux d'indemnisation	H0 propre à la banque	XGBoost retenu
Older American	17,4 %	1,09 [0,97 ; 1,22]	1,00 [0,90 ; 1,11]
Servicemember	14,0 %	0,90 [0,80 ; 1,00]	1,02 [0,91 ; 1,15]
Cartes de crédit	16,5 %	**2,39** [2,20 ; 2,61]	**3,72** [3,34 ; 4,13]
Comptes courants et d'épargne	12,5 %	**0,42** [0,38 ; 0,46]	**0,27** [0,24 ; 0,30]

Table 24 – Rapport des Capture@10 % avec une file par banque, sur la validation

Les clients signalés comme âgés ou militaires ne sont pas désavantagés : les quatre rapports restent dans les seuils. Le produit, en revanche, échoue nettement, et pour les deux candidats.

Une réclamation sur un compte courant ou d'épargne qui finira indemnisée n'a que 10,9 % de chances d'être traitée en priorité avec H0, et 7,7 % avec XGBoost, contre 26 à 29 % pour une carte de crédit. Un tri au hasard ferait aussi bien, ou mieux. La cause est mécanique. Les cartes de crédit sont plus souvent indemnisées (16,5 % contre 12,5 %), donc toutes leurs réclamations reçoivent des notes plus hautes, et elles occupent presque toutes les places de tête dans les banques qui gèrent les deux produits. Les clients des comptes courants se retrouvent relégués, même quand leur dossier est fondé. Le meilleur modèle aggrave l'effet, parce qu'il sépare mieux les deux produits.

Ce n'est pas un défaut de modèle : la règle simple échoue aussi. C'est un défaut de conception de l'outil, qui met en concurrence des dossiers que rien n'oblige à comparer.

8.4 La correction : une file par produit

La correction consiste à réserver à chaque produit sa part des places prioritaires : chaque banque traite d'abord 10 % de ses réclamations sur les cartes et 10 % de ses réclamations sur les comptes. C'est aussi l'organisation la plus courante en pratique, où des équipes différentes traitent

les litiges de carte et ceux des comptes. La file devient donc le couple établissement et produit, défini une seule fois dans le code (`complaint_triage.evaluation.queues`).

Je n'ai pas retenu une autre solution, qui consistait à retirer le produit des critères d'équité au motif que ce n'est pas un groupe de clients. Ce serait changer la règle après avoir vu le résultat, alors que le préjudice est réel pour les clients concernés. Le contrôle d'équité a joué le rôle que lui donnait le cadrage : il a fait changer la conception de l'outil. Les seuils, eux, n'ont pas bougé.

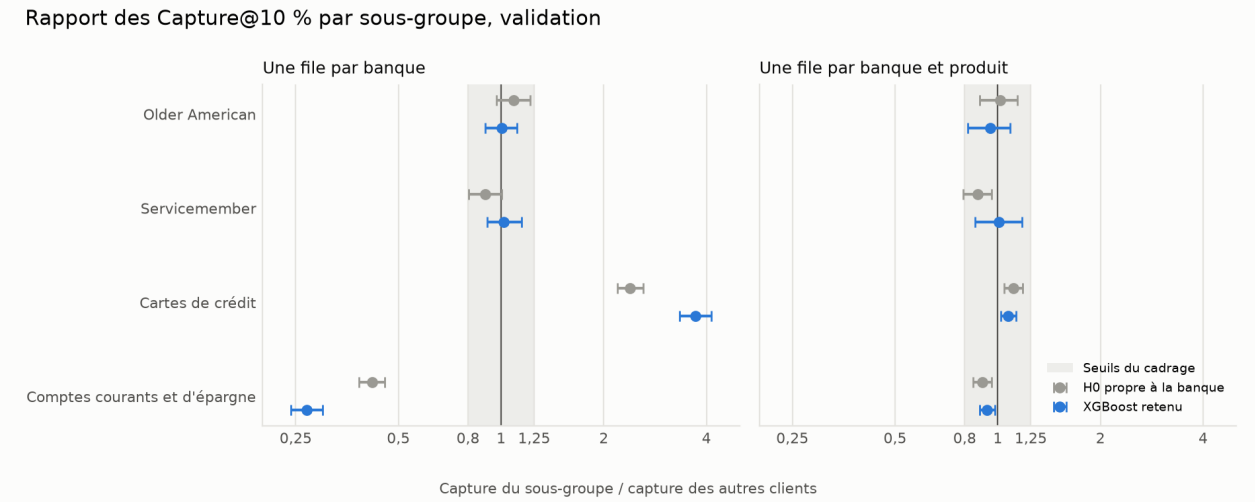


Figure 10 – Rapport des Capture@10 % entre chaque sous-groupe et les autres clients, avant et après la correction. La bande grise marque les seuils du cadrage ; l'échelle est logarithmique.

Sous-groupe	H0 propre à la banque	XGBoost retenu
Older American	1,02 [0,89 ; 1,14]	0,95 [0,82 ; 1,09]
Servicemember	0,87 [0,79 ; 0,96]	1,01 [0,86 ; 1,18]
Cartes de crédit	1,11 [1,04 ; 1,18]	1,08 [1,02 ; 1,13]
Comptes courants et d'épargne	0,90 [0,85 ; 0,96]	0,93 [0,88 ; 0,98]

Table 25 – Rapport des Capture@10 % avec une file par banque et par produit, sur la validation

Avec une file par produit, tous les rapports rentrent dans les seuils. Un écart demande toutefois d'être suivi : avec H0, les clients militaires sont un peu moins souvent traités en priorité que les autres (0,87), et cette fois l'intervalle exclut 1. Le rapport reste au-dessus de 0,8, mais l'écart n'est probablement pas dû au hasard. XGBoost ne le montre pas (1,01).

8.5 Ce que coûte la correction

Classement	Une file par banque	Une file par banque et produit
H0 propre à la banque	19,4 %	18,4 %
XGBoost retenu	19,4 %	19,0 %
Écart XGBoost – H0 [IC 95 %]	$0{,}0\ [-0{,}5\,;\,+0{,}5]$	$+0{,}6\ [+0{,}1\,;\,+1{,}2]$

Table 26 – Capture@10 % sur la validation selon l'organisation des files

Réserver des places à chaque produit coûte environ un point de Capture@10 % à H0, et un peu moins à XGBoost. C'est le prix d'un traitement équitable entre les deux produits : on capte un peu moins de réclamations indemnisées au total, mais celles des comptes courants ne sont plus sacrifiées. Avec les nouvelles files, XGBoost dépasse légèrement H0, de 0,6 point, loin de la marge de 5 points.

8.6 Calibration



Figure 11 – Note moyenne et part réellement indemnisée dans chacune des 10 classes de notes, sur la validation.

Population	H0 propre à la banque	XGBoost retenu
Toutes les réclamations	0,022	0,009
Older American	0,025	0,021
Servicemember	0,026	0,019
Cartes de crédit	0,032	0,020
Comptes courants et d'épargne	0,014	0,006

Table 27 – Erreur de calibration (ECE) sur la validation ; le seuil est 0,05

Les deux candidats respectent le seuil, dans l'ensemble comme dans chaque sous-groupe. H0 surestime un peu le risque : 16,5 % en moyenne, pour 14,5 % de réclamations réellement indemnisées. Ses taux sont calculés sur toute la période d'entraînement, depuis 2022, alors que le taux d'indemnisation a baissé depuis (rapport de cadrage, section 5). XGBoost suit mieux le niveau récent, sans doute en partie parce que son apprentissage s'arrête d'après les trois derniers mois de l'entraînement. Aucun recalibrage n'est nécessaire, mais cette dérive confirme qu'il faudra surveiller la calibration en production.

8.7 Conséquences

Constat	Conséquence
Avec une file par banque, les comptes courants sont relégués	Chaque banque traite en priorité 10 % de la file de chaque produit ; cette définition s'applique à la décision finale
Les clients âgés ou militaires ne sont pas désavantagés	Les deux candidats restent éligibles
H0 traite un peu moins vite les clients militaires (0,87)	À surveiller en production, avec les autres rapports
La calibration respecte le seuil	Aucun recalibrage ; suivi de la dérive en production

Table 28 – Bilan de l'étape 7

9. Décision sur la période de test

9.1 Le protocole, écrit avant d'ouvrir le test

La période de test couvre les réclamations reçues du 1er janvier au 19 juillet 2026, soit 99 089 réclamations sur 29 semaines ; les plus récentes n'ont pas encore 90 jours d'ancienneté et restent exclues. Elle n'a servi à aucun choix. Le protocole ci-dessous a été écrit et versionné avant son ouverture, et l'historique Git en garde la date.

1. **Réentraînement.** H0 propre à la banque et le XGBoost retenu (variante D, profondeur 4, feuille minimale 100) sont réentraînés sur l'entraînement et la validation réunis, jusqu'au 31 décembre 2025. XGBoost arrête son apprentissage d'après les trois derniers mois de 2025. Aucun autre réglage ne change.
2. **Mesure.** Capture@10 % chaque semaine dans la file de chaque banque et de chaque produit (section 8), intervalles par bootstrap sur les semaines.
3. **Modèle structuré.** XGBoost n'est retenu que s'il fait au moins 5 points de plus que H0 propre à la banque, et si la borne basse de l'intervalle de l'écart est au-dessus de zéro. Sinon, H0 propre à la banque est retenu.
4. **Mise en service.** Le classement retenu doit respecter les seuils d'équité (rapports entre 0,8 et 1,25 pour les quatre sous-groupes) et de calibration (ECE sous 0,05) sur le test. Sinon, la mise en service est bloquée.
5. **Texte.** Le modèle de texte retenu sur la validation est le TF-IDF, à résultat égal avec DistilRoBERTa et bien plus simple. Il est réentraîné sur les récits de l'entraînement et de la validation, chaque récit recopié n'étant gardé qu'une fois. Il est gardé si sa PR-AUC dépasse d'au moins 0,02 celle du classement retenu, sur les récits de test jamais vus pendant l'apprentissage.

Le critère du texte demande une précision. Au cadrage, la PR-AUC était implicitement calculée en mélangeant toutes les banques. Elle a le même défaut que l'ancienne Capture (section 6) : elle récompense un classement qui reconnaît la banque. Sur la validation, ce choix change la conclusion. Banques mélangées, le TF-IDF ne gagne que 0,014 sur H0 propre à la banque, parce que H0 profite de sa connaissance des taux de chaque établissement ; dans les files, il gagne 0,068. Par cohérence avec la correction de la section 6, la PR-AUC qui fait foi est calculée dans chaque file (banque et produit), puis moyennée en pondérant par le nombre de réclamations indemnisées.

La version mélangée est publiée à côté. Ce choix a été fixé avant l'ouverture du test, et il favorise le texte : je le signale pour que le lecteur puisse en juger.

Le script de décision (`scripts/evaluation/decide_on_test.py`) applique ces règles telles qu'elles sont écrites dans le code (`complaint_triage.evaluation.decision`), et refuse de tourner une seconde fois. Avant d'ouvrir le test, je l'ai exécuté en répétition sur la validation, avec un apprentissage limité à l'entraînement : il retrouve exactement les chiffres de la section 8 (18,4 % pour H0 propre à la banque, 19,0 % pour XGBoost) et ceux de la section sur le texte.

9.2 Le modèle structuré

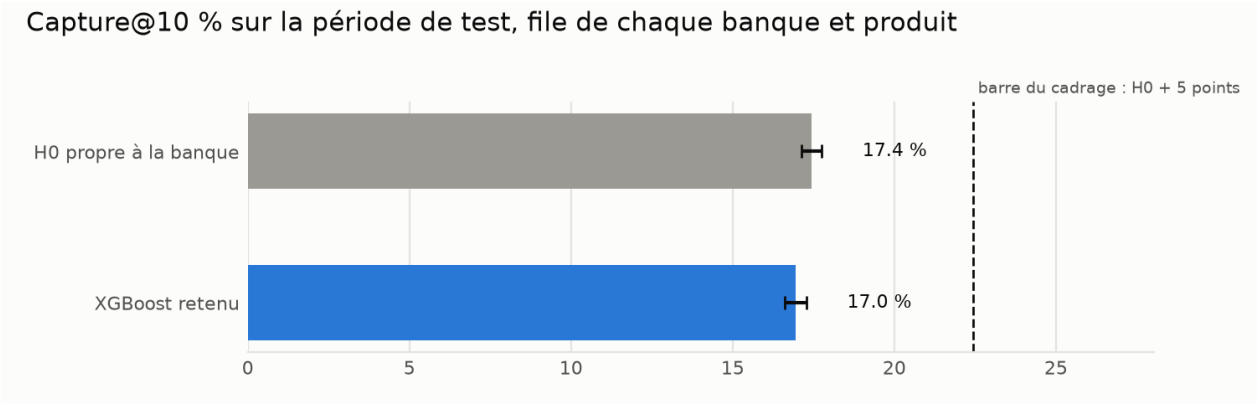


Figure 12 – Capture@10 % sur la période de test (janvier à juillet 2026), dans la file de chaque banque et de chaque produit. La ligne pointillée marque la barre fixée au cadrage.

Classement	Capture@10 % [IC 95 %]	Écart avec H0 propre à la banque [IC 95 %]	PR-AUC dans les files
H0 propre à la banque	17,4 % [17,1 ; 17,7]	–	0,338
XGBoost retenu	17,0 % [16,6 ; 17,3]	$-0{,}5$ [$-0{,}8$; $-0{,}1$]	0,346

Table 29 – Les deux candidats sur les 99 089 réclamations de test

XGBoost ne fait pas mieux que la règle propre à chaque banque : il fait même un peu moins bien, de 0,5 point, et cette fois l'intervalle exclut zéro. Le petit avantage mesuré sur la validation (+0,6 point) ne s'est pas confirmé. C'est exactement le cas que la marge de 5 points et le test unique devaient couvrir : un écart modeste, choisi parmi plusieurs essais sur la même validation, ne survit pas toujours à une période nouvelle. Le critère n'est pas atteint, et H0 propre à la banque est retenu.

Les deux classements captent un peu moins qu'en validation (17,4 % contre 18,4 % pour H0), alors que le taux d'indemnisation est un peu plus élevé sur le test (15,2 % contre 14,5 %). Le tri reste nettement meilleur que le hasard (10 %).

9.3 Équité et calibration sur le test

Sous-groupe	H0 propre à la banque	XGBoost retenu
Older American	0,93 [0,86 ; 1,01]	1,01 [0,90 ; 1,14]
Servicemember	1,12 [1,03 ; 1,21]	1,10 [0,99 ; 1,22]
Cartes de crédit	1,06 [0,99 ; 1,13]	1,06 [1,00 ; 1,13]
Comptes courants et d'épargne	0,94 [0,88 ; 1,01]	0,94 [0,89 ; 1,00]
ECE	0,024	0,006

Table 30 – Rapports des Capture@10 % et erreur de calibration sur le test

Le classement retenu respecte tous les seuils sur le test : les rapports vont de 0,93 à 1,12, et l'ECE vaut 0,024. L'écart repéré en validation pour les clients militaires (0,87) ne se retrouve pas : sur le test, ils sont au contraire un peu plus souvent traités en priorité que les autres (1,12). L'écart de la validation était donc probablement propre à cette période. Ces rapports bougent d'une période à l'autre, ce qui confirme qu'il faut les suivre en continu plutôt que les mesurer une fois.

H0 continue de surestimer le risque : 17,6 % en moyenne pour 15,2 % de réclamations indemnisées. Cela ne change rien au classement, mais la note affichée aux chargés de réclamations devra être recalculée sur une période récente avant la mise en production.

9.4 Le texte

Classement	Capture@10 %	Écart [IC 95 %]	PR-AUC dans les files	PR-AUC mélangée
H0 propre à la banque	16,8 %	–	0,353	0,383
XGBoost retenu	16,3 %	$-0{,}6$ [$-1{,}1$; $0{,}0$]	0,359	0,375
TF-IDF (texte seul)	19,4 %	$+2{,}6$ [$+1{,}8$; $+3{,}4$]	0,416	0,391

Table 31 – Sur les 40 412 récits de test jamais vus pendant l'apprentissage

Le texte confirme ce qu'il montrait en validation : environ 2,6 points de Capture@10 % de plus que H0 propre à la banque, avec un intervalle loin de zéro. Sa PR-AUC dans les files dépasse celle du classement retenu de 0,063, plus de trois fois le seuil de 0,02 : le critère est atteint et le texte est gardé. Calculée en mélangeant les banques, la différence n'aurait été que de 0,008, sous le seuil ; c'est la conséquence attendue du choix fixé dans le protocole.

« Gardé » a ici un sens précis. Le CFPB ne publie plus de récits : le système alimenté par ses données ne peut pas utiliser le texte. Le modèle de texte reste un composant documenté et mesuré, utilisable par une banque qui dispose du texte de ses propres réclamations. Il ne remplace pas le moteur de priorisation.

9.5 La décision

Critère	Seuil du cadrage	Résultat sur le test	Verdict
Modèle structuré	H0 + 5 points, borne basse au-dessus de H0	$-0{,}5$ $[-0{,}8\,;\,-0{,}1]$	Non atteint
Texte	PR-AUC + 0,02	+ 0,063	Atteint
Équité	Rapports entre 0,8 et 1,25	De 0,93 à 1,12	Respecté
Calibration	ECE inférieure à 0,05	0,024	Respecté

Table 32 – Les critères de la v0.1 appliqués au classement retenu

Le moteur de priorisation est la règle H0 propre à chaque banque : ses taux historiques d'indemnisation par produit, motif et sous-motif, rapprochés de ceux du marché quand elle a peu de réclamations, appliqués chaque semaine à 10 % de la file de chaque produit. Il respecte les seuils d'équité et de calibration, et la mise en service est possible. Le modèle de texte est conservé comme composant optionnel pour une banque qui dispose de ses propres récits.

10. Conclusion de la v0.1

10.1 Ce que la version a établi

La v0.1 devait dire si un modèle d'apprentissage automatique classe mieux les réclamations qu'une règle simple, à partir des seules données disponibles à la réception. La réponse est non. Sans le texte, aucune variante d'XGBoost ne fait mieux qu'une banque qui calcule ses propres taux d'indemnisation par motif. Le texte apporte un vrai signal, de l'ordre de 3 points, mais il n'est plus publié.

Ce résultat négatif est un résultat. Il évite de déployer et de maintenir un modèle qui coûterait plus cher qu'une règle de tableur sans servir mieux le client. Il a été obtenu avec un cadre qui rendait les faux succès difficiles : seuils fixés au cadrage, découpage dans le temps, intervalles par semaines, test ouvert une seule fois, protocole versionné avant l'ouverture.

10.2 Ce qui a changé en cours de route

Deux corrections ont modifié la mesure, et elles sont documentées comme telles. La première (section 6) classe les réclamations dans la file de chaque banque plutôt que toutes ensemble : elle a fait disparaître un gain de 3 points qui venait de la reconnaissance des banques. La seconde (section 8) sépare les files par produit, après que le contrôle d'équité a montré que les clients des comptes courants étaient relégués. Aucune n'a assoupli une exigence : la première a rendu la mesure plus sévère, la seconde a coûté un point de capture.

10.3 Pour la suite

— **v0.2 et v0.3.** Le RAG et l'agent s'appuient sur la règle H0 propre à chaque banque.

— **v0.4.** Les scénarios vérifient que l'agent ne retarde jamais un dossier au-delà du délai.

— **v1.0.** Taux recalculés chaque mois ; suivi hebdomadaire de la capture, de l'équité et de la calibration.